

REDES NEURAIS ARTIFICIAIS (RNA)

Prof. Valmir Macario Filho

DC-UFRPE



OBJETIVO

- Introduzir a teoria das Redes Neurais Artificiais, conceitos básicos e principais algoritmos de aprendizado supervisionado e não-supervisionado, fornecendo subsídios para que o aluno saiba discernir quando se deve utilizar as Redes Neurais como ferramenta;
- Apresentar ferramentas de software de Redes Neurais;
- Exemplificar sua aplicação em sistemas de previsão, apoio à decisão, classificação e reconhecimento de padrões.



CONTEÚDO PROGRAMÁTICO

1. Introdução - Conceitos iniciais

1.1 Neurônios Biológicos Vs. Artificiais

1.2 Funções de Ativação

1.3 Principais Arquiteturas

1.4 Processos de Treinamento e Aspectos de Aprendizado

2. Redes de Função de Base Radial

2.1 Funcionamento

2.2 Processo de Treinamento

2.3 Aplicações

3. Redes Auto-organizáveis de Kohonen

3.1 Aprendizado competitivo

3.2 Mapas SOM

3.3 Aplicações

4. Redes Recorrentes de Hopfield

4.1 Funcionamento

4.2 Processo de Treinamento

4.3 Aplicações



CONTEÚDO PROGRAMÁTICO

5. Regressão linear

5.1 Funcionamento

5.2 Processo de Treinamento

6. Redes Perceptron Multicamadas

6.1 Funcionamento

6.2 Processo de Treinamento

6.3 Especificação da Topologia

7. Redes Neurais Convolutivas

7.1 Funcionamento

7.2 Processo de Treinamento

7.3 Especificação da Topologia



FERRAMENTAS DE APOIO

- Weka
- Scikit-learning
- Keras
- PyTorch



BIBLIOGRAFIA

- Simon Haykin. Redes Neurais: Princípios e Práticas 2ª Edição. Bookman, 2001.
- Antônio de Pádua Braga, André Ponce de Leon F. De Carvalho e Teresa Bernarda Ludermir. Redes Neurais Artificiais – Teoria e Aplicações - 2ª EDIÇÃO, 2007. RUSSEL, S.; NORVIG, P. Inteligência Artificial - Tradução da Segunda Edição. Rio de Janeiro: Elsevier, 2004.
- MITCHELL, T. M. Machine Learning. Singapore: McGraw-Hill, 1997.
- BISHOP, C. M. (2006). Pattern Recognition and Machine Learning. Springer.



MATERIAL EXTRA

- <http://deeplearning.net/>
- <https://medium.com/>
- <https://towardsdatascience.com/>
- <https://www.guru99.com>
- [Siraj Raval](#)



CONFERÊNCIAS MAIS IMPORTANTES

- IEEE Conference on Computer Vision and Pattern Recognition (CVPR)
- Neural Information Processing Systems (NIPS)
- European Conference on Computer Vision (ECCV)
- International Conference on Machine Learning (ICML)
- IEEE International Conference on Computer Vision (ICCV)



AVALIAÇÃO

- 1ª VA
 - Seminários (3 pts)
 - Lista de exercícios (3 pts)
 - Mini-projetos (4 pts)

- 2ª VA
 - Seminários
 - Projeto prático

- 3ª VA
 - Prova escrita valendo 4 pontos para 3ª VA
 - Projeto prático valendo 6 pontos para 3ª VA

- Final
 - Projeto prático valendo 2 pontos para FINAL
 - Prova escrita valendo 8 pontos para FINAL

OBS 3: Na 3ª VA será necessário incrementar o projeto realizado na 2ª VA, valendo até 6 pontos.



ADMINISTRAÇÃO DO CURSO


- Cronograma, Notas de Aula, Exercícios e Material
 - Estarão disponíveis no site:
 - <http://ava.ufrpe.br/>
 - [https://github.com/valmirf/redes neurais](https://github.com/valmirf/redes_neurais)
 - <https://classroom.google.com/u/1/c/NjIzNDA4MzI4Njha>
- Faltas
 - Chamadas todas as aulas



EXPERIÊNCIA DO PROFESSOR

- Mestrado e Doutorado na área de inteligência artificial na UFPE
- Publicações na área:
- **MACÁRIO, V.**; PRUDENCIO, R. B. C. ; DE CARVALHO, F. A. T. ; TORRES, L. R. ; Rodrigues Júnior, R. ; LIMA, M. G. . Automatic Information Extraction in Semi-Structured Official Journals. In: Brazilian Symposium on Neural Networks, 2008, Salvador. Proceedings of the 10th Brazilian Symposium on Neural Networks, 2008. p. 51-56.
- Metaclasses and zoning for handwritten document recognition. In: 2013 International Joint Conference on Neural Networks (IJCNN 2013 Dallas), 2013, Dallas. The 2013 International Joint Conference on Neural Networks (IJCNN). p. 1-2509.
- LUNA DA SILVA, RICARDO ; CHEVTCHENKO, SERGIO ; ALVES DE MOURA, ALLAN ; ROLIM CORDEIRO, FILIPE ; **MACARIO, VALMIR** . Detecting People from Beach Images. In: 2017 IEEE 29th International Conference on Tools with Artificial Intelligence (ICTAI), 2017, Boston. 2017 IEEE 29th International Conference on Tools with Artificial Intelligence (ICTAI), 2017. p. 636.
- CHEVTCHENKO, S. ; VALE, R. F. ; MACARIO, V. . Multi-Objective Optimization for Hand Posture Recognition. EXPERT SYSTEMS WITH APPLICATIONS, p. 170-181, 2017.
- PACIFICO, L. D. S. ; **MACARIO, V.** ; OLIVEIRA, J. F. L. . Plant Classification Using Artificial Neural Networks. In: International Joint Conference on Neural Networks (IJCNN), 2018, Rio de Janeiro. Proceedings of International Joint Conference on Neural Networks (IJCNN), 2018.
- CHEVTCHENKO, S. ; VALE, R. F. ; CORDEIRO, F. R. ; **MACARIO, V.** Deep Learning for People Detection on Beach Images. In: Brazilian Conference on Intelligent Systems (BRACIS), 2018, São Paulo. Proceedings of Brazilian Conference on Intelligent Systems, 2018.
- CHEVTCHENKO, S. ; VALE, R. F. ; MACARIO, V. ; CORDEIRO, F. R. . A convolutional neural network with feature fusion for real-time hand posture recognition. APPLIED SOFT COMPUTING, v. 73, p. 748-766, 2018





INTRODUÇÃO À REDES NEURAIS

INTRODUÇÃO

- As redes neurais são um tema da computação altamente inspirada na natureza que nos cerca.
- Durante anos e anos os homens trabalharam para fazer computadores mais rápidos e mais potentes
- Apesar do seu incrível poder computacional estes computadores falhavam em fazer tarefas que uma criança de 3 anos faria imediatamente
- Exemplo: reconhecer uma pessoa ou aprender algo novo só com a experiência.

INTRODUÇÃO

- Baseado nisto, resolveu-se então buscar criar um modelo computacional que emulasse o comportamento do cérebro humano.
- Criaram-se neurônios artificiais extremamente similares aos humanos e interligaram-nos para formar redes que mostraram poder fazer tarefas antes restritas aos cérebros
- Quem sabe assim, poderíamos criar computadores tão inteligentes quanto uma criança de 3 anos de idade?

INTRODUÇÃO


- IA Simbólica tenta simular o comportamento inteligente humano desconsiderando os mecanismos responsáveis por tal
- Considera que a cognição pode ser explicada através de operações sobre símbolos. Estas operações são teorias computacionais e modelos de mente (excluindo-se os modelos cerebrais)
- Processos mentais são análogos a procedimentos realizados por computadores



INTRODUÇÃO

- IA Conexionista acredita que construindo um sistema que simule a estrutura do cérebro, este apresentará inteligência, ou seja, será capaz de, assimilar, errar e aprender com seus erros
- A cognição só pode ser modelada e explicada por um modelo que leve em conta a estrutura física/biológica do cérebro. A classe principal destes modelos são as redes neurais artificiais






**Fotomicrografia de três
neurónios coloridos
artificialmente**

NEURÔNIOS “NATURAIS”

- Estruturas da Célula
 - Corpo celular
 - Dendritos
 - Axônio
 - Terminais sinápticos



NEURÔNIOS “NATURAIS”

Componentes de um Neurônio

- **Axônio** – transmissão de sinais a partir do corpo celular; poucas ramificações e compridos;
- **Dendritos** – conduzem sinais para a célula; têm muitas ramificações (zonas receptivas);
- **Sinapses** – estruturas funcionais elementares que mediam as conexões entre os neurônios

AS SINAPSES

- Em condições normais, como já afirmamos anteriormente, duas células nervosas se associam estabelecendo contato entre o dendrito de uma e o axônio de outra
- Esta modalidade de associação recíproca é chamada de sinapse.
- Existem basicamente dois tipos de sinapse no mundo animal:
 - as sinapses elétricas
 - as sinapses químicas.
- As sinapses químicas conduzem a informação em somente uma direção, ou seja, do neurônio que secreta o transmissor, denominado pré-sináptico para o neurônio que recebe a ação do neurotransmissor, denominado pós-sináptico

SINAPSES


- O armazenamento da informação é o processo que chamamos memória e é também função da sinapse.
- Isto é, cada vez que um impulso sensorial particular passa através de uma sequência de sinapses, estas sinapses tornam-se mais capazes de transmitir o mesmo impulso da próxima vez
- Este processo é conhecido como facilitação
- É o que o treinamento das redes neurais gostaria de imitar.

NEURÔNIOS TRABALHANDO...

- Todo neurônio tem um pequeno potencial elétrico de repouso na sua membrana, da ordem de -65mV .
- A ação dos neurônios anteriores pode inibir ou excitar um neurônio pós-sináptico respectivamente diminuindo (inibindo, ou tornando mais negativo) ou aumentando (excitando, ou tornando menos negativo) o valor de seu potencial.
- A ação dos neurônios pré-sinápticos se soma em um neurônio e altera seu potencial elétrico.
- Quando este atinge a marca de -45mV , o neurônio atinge o que se chama potencial de ação.
- Para atingir este estado é necessária a atuação de vários neurônio pré-sinápticos (cerca de 70 para o neurônio motor típico)


COMUNICAÇÃO NEURAL

- Potencial elétrico através da membrana da célula exibe picos.
- Pico se origina no corpo celular, passa pelo axônio, e faz com que os terminais sinápticos soltem neurotransmissores.
- Neurotransmissores passam através das sinapses para os dendritos de outros neurônios.
- Se a entrada total de neurotransmissores para um neurônio é excitatória e ultrapassa um certo limite, ele dispara (tem um pico).



NEURÔNIOS TRABALHANDO...

➤ Graficamente:



REDES NEURAIS NATURAIS

- Nós nascemos com cerca de 100 bilhões de neurônios
- Um neurônio pode se conectar com até 100.000 outros neurônios.



REDES NEURAIS NATURAIS

- **Plasticidade de um neurônio** – capacidade de adaptação ao ambiente.
- Mecanismos de Plasticidade (cérebro de um adulto)
 - Criação de novas conexões sinápticas
 - Modificação das sinapses existentes
- Plasticidade - essencial para as Redes Neurais Artificiais


CARACTERÍSTICAS DAS RNAS

- Aprendem através de exemplos
 - Inferência estatística não paramétrica
- Adaptabilidade
- Capacidade de generalização
- Tolerância a falhas
- Implementação rápida




REDES NEURAIS ARTIFICIAIS

Inspiração Biológica




Redes Neurais Artificiais


Exemplos de Redes Neurais




a) Single-Layer Perceptron




d) Elman recurrent network




b) Multi-Layer Perceptron



e) Competitive networks



c) Hopfield network



f) Self-Organizing Maps


HISTÓRICO

HISTÓRICO (1943)

O neurofisiologista McCulloch e matemático Walter Pitts (1943), cujo trabalho fazia uma analogia entre células vivas e o processo eletrônico, simulando o comportamento do neurônio natural, onde o neurônio possuía apenas uma saída, que era uma função do valor de suas diversas entradas.

O NEURÔNIO DE MCCULLOCH E PITTS

- Consiste basicamente de um neurônio que executa uma função lógica
- Os nós produzem somente resultados binários e as conexões transmitem exclusivamente zeros e uns
- As redes são compostas de conexões sem peso, de tipos excitatórios e inibitórios.
- Cada unidade é caracterizada por um certo limiar (*threshold*)



HISTÓRICO (1949)

O psicólogo Donald Hebb, demonstrou que a capacidade da aprendizagem em redes neurais biológicas vem da alteração da eficiência sináptica, isto é, a conexão somente é reforçada se tanto as células pré-sinápticas quanto as pós-sinápticas estiverem excitadas;

Hebb foi o primeiro a propor uma lei de aprendizagem específica para as sinapses dos neurônios.

HISTÓRICO (1956)

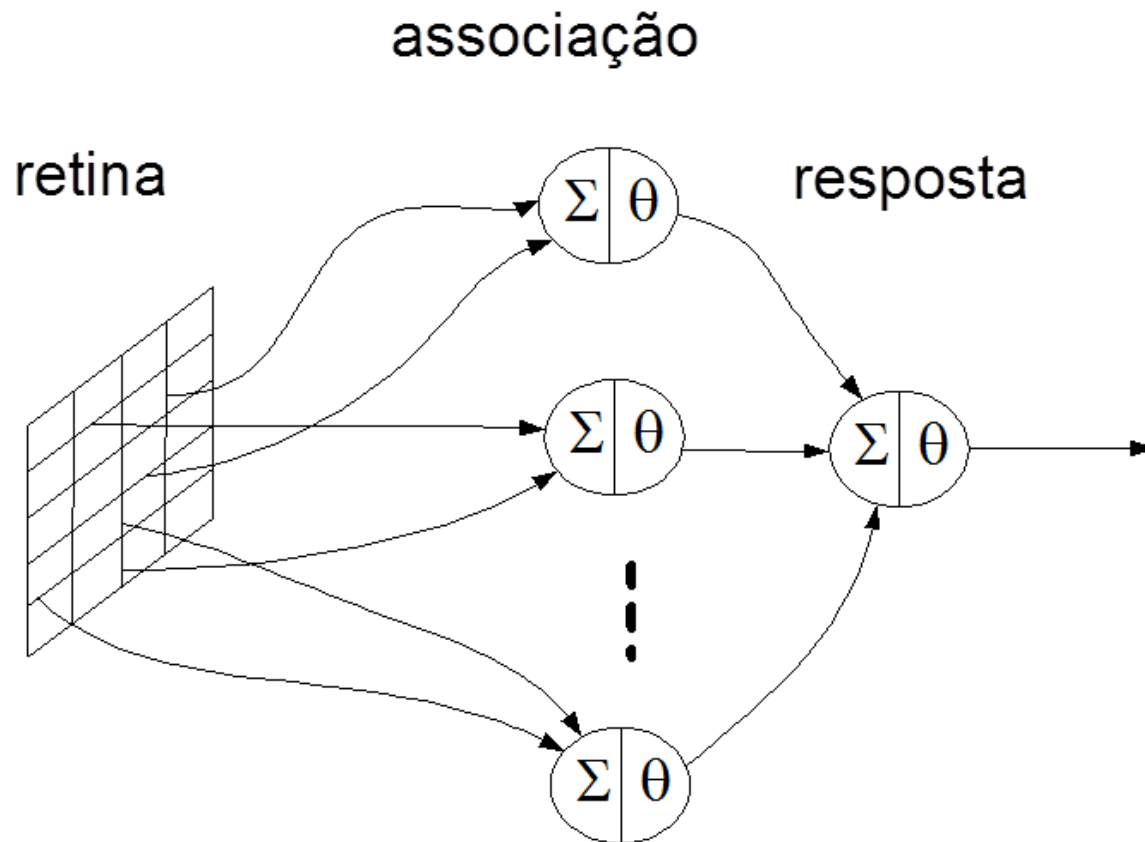
- Surgimento dos dois paradigmas da Inteligência Artificial:
 - Simbólica: tenta simular o comportamento inteligente humano desconsiderando os mecanismos responsáveis por tal.
 - Conexionista: acredita que construindo-se um sistema que simule a estrutura do cérebro, este sistema apresentará inteligência, ou seja, será capaz de aprender, assimilar, errar e aprender com seus erros.

HISTÓRICO (1958)

Rosemblatt (1958) mostrou em seu livro (Principles of Neurodynamics) o modelo dos "Perceptrons".

Nele, os neurônios (Perceptrons) eram organizados em camada de entrada e saída, onde os pesos das conexões eram adaptados a fim de se atingir a eficiência sináptica usada no reconhecimento de caracteres.

PERCEPTRON CLÁSSICO – ROSENBLATT (1958)



HISTÓRICO (1960)

Em 1960 surgiu a rede ADALINE (ADApative LInear NEtwork) e o MADALINE (Many ADALINE), proposto por Widrow e Hoff.

O ADALINE/MADALINE utilizou saídas analógicas em uma arquitetura de três camadas.

HISTÓRICO (1969)

- Foi constatado por Minsky & Papert que um neurônio do tipo Perceptron só é capaz de resolver problemas com dados de classes linearmente separáveis.

HISTÓRICO (1960-1970)

Muitos historiadores desconsideram a existência de pesquisa nessa área nos anos 60 e 70.

HISTÓRICO (1982)

Retomada das pesquisas com a publicação dos trabalhos do físico e biólogo Hopfield relatando a utilização de redes simétricas para otimização, através de um algoritmo de aprendizagem que estabilizava uma rede binária simétrica com realimentação.

HISTÓRICO (1986)

- Rumelhart, Hinton e Williams introduziram o poderoso método de treinamento denominado “Backpropagation”.
- Rumelhart e McClelland escreveram o livro “Processamento Paralelo Distribuído: Explorações na Microestrutura do Conhecimento”.

HISTÓRICO (1988)

- Broomhead e Lowe descreveram um procedimento para o projeto de uma rede neural (feedforward) usando funções de base radial (Rede de Base Radial – RBF).

HISTÓRICO (2000)

- As combinações de Redes Neurais melhoram os resultados em várias aplicações;
- Os algoritmos Máquina de Vetor de Suporte (SVM) é lançado e pela facilidade de uso ganha bastante atenção;
- O algoritmo de treinamento de Levenberg-Marquardt (2008) é mais rápido que o gradiente descendente e se torna aposta para melhorar a velocidade de treinamento das redes neurais.



HISTÓRICO (APRENDIZADO PROFUNDO)

- **1959** - Descoberta de tipos de células do cortex visual.
 - David H. Hubel and Torsten Wiesel
- **1965** – O primeiro trabalho com a ideia de aprendizado profundo
 - Alexey Ivakhnenko and V.G. Lapa
 - Experimentos com uma rede neural feed-forward de 8 camadas.
- **1989** - Rede Convolutiva Lenet-5 (Yann LeCun)
 - Primeira vez que uma rede neural com a ideia de convolução é utilizada para reconhecimento de documentos.




HISTÓRICO (APRENDIZADO PROFUNDO)

- **2009** - Fei-Fei Li lança o desafio da ImageNet
 - Uma base de dados de imagens com cerca de 14 milhões de imagens
- **2011** - AlexNet - Alex Krizhevsky
 - A rede AlexNet é uma melhoria da Lener-5. Inicialmente continha 8 camadas, 5 convolutivas e 3 totalmente conectadas, utilizando ideias como dropout e RELU.
 - O sucesso dessa rede impulsionou o renascimento da pareia de aprendizado profund na área. E atualmente são as redes neurais mais utilizadas em diversas aplicações da computação inteligente.
- **2018** – Prêmio Turing
 - Yoshua Bengio, Geoffrey Hinton e Yann LeCun ganham o “prêmio nobel da computação”, o prêmio Turing. Esse é o reconhecimento da importância dessa área para a computação.



IMAGENET

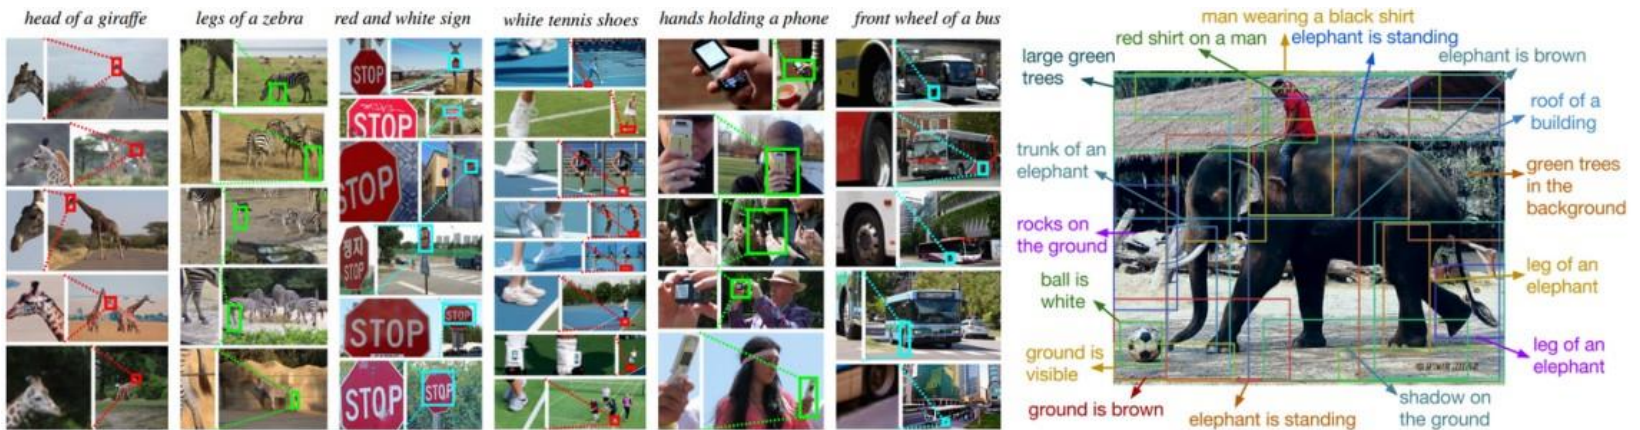
Competição Imagenet





APLICAÇÕES

DESCRIÇÃO DE IMAGENS



ALPHAGO

- Go é jogado entre dois jogadores.
- Um dos jogadores usa as pedras brancas e o outro as pretas.
- A pedra deve ser colocada em um dos cruzamentos.
- O jogador que obtém mais território ganha o jogo.



ALPHAGO

- O algoritmo possui uma primeira etapa supervisionada, treinada com milhões de jogadas.
- Depois, através do aprendizado por reforço, o jogo joga contra si mesmo.
- Avalia através do método de busca árvore Monte Carlo uma infinidade de movimentos possíveis.
- O método extremo de aprendizado equivale à experiência de muitas vidas humanas.



CARROS AUTÔNOMOS



CARROS AUTÔNOMOS

- Importância:
 - Morre uma pessoa de acidente de carro a cada 23 segundos
- Carros:
 - Tesla (2020)
 - GM (2019 – Atrasou e não disse nova data)
 - Ford (2021)
 - Honda (Na estrada, 2020)
 - Toyota (Na estrada, 2020)
 - Renault, Nissan (Na estrada 2020, Na cidade 2025)
 - Volvo (Na estrada, 2021)
 - Hyundai (Na estrada 2020, Na cidade 2030)
 - Fiat-Chrysler (Na estrada, 2021)
 - BMW (Na cidade, 2021)



DIAGNÓSTICO DE CÂNCER

- Nível de diagnóstico de câncer no mesmo nível que especialistas humanos (2017)





Skin lesion image

Deep convolutional neural network (Inception v3)

Training classes (757)

Inference classes (varies by task)



- Convolution
- AvgPool
- MaxPool
- Concat
- Dropout
- Fully connected
- Softmax

- Acral-lentiginous melanoma
- Amelanotic melanoma
- Lentigo melanoma
- ...
- Blue nevus
- Halo nevus
- Mongolian spot
- ...

- 92% malignant melanocytic lesion
- 8% benign melanocytic lesion



DIAGNÓSTICO DE CÂNCER

- Nível de diagnóstico de câncer é melhor que especialistas humanos (2020)
- O sistema identificou 5,7% de falsos diagnósticos a mais que os médicos nas pacientes norte-americanas, enquanto entre as britânicas essa taxa foi de 1,2%.
- Além disso, a inteligência artificial conseguiu realizar diagnósticos positivos que os médicos haviam deixado passar - Nos Estados Unidos a proporção de casos diminuiu 9,4%, na Grã Bretanha essa taxa foi de 2,7%.

Article

International evaluation of an AI system for breast cancer screening

<https://doi.org/10.1038/s41586-019-1799-6>

Received: 27 July 2019

Accepted: 5 November 2019

Published online: 1 January 2020

Scott Mayer McKinney^{1,2,4}, Marcin Sieniek^{1,2,4}, Varun Godbole^{1,2,4}, Jonathan Godwin^{1,2,4}, Natasha Antropova², Hutan Ashrafian^{3,4}, Trevor Back², Mary Chesus², Greg C. Corrado¹, Ara Darzi^{3,4,5}, Mozziyar Etemadi⁶, Florencia Garcia-Vicente⁶, Fiona J. Gilbert⁷, Mark Halling-Brown⁸, Demis Hassabis², Sunnry Jansen⁹, Alan Karthikesalingam¹⁰, Christopher J. Kelly¹⁰, Dominic King¹⁰, Joseph R. Ledsam², David Melnick⁶, Hormuz Mostofi¹, Lily Peng¹, Joshua Jay Reicher¹⁰, Bernardino Romera-Paredes², Richard Sibiabala^{10,11}, Mustafa Suleyman², Daniel Tse¹², Kenneth C. Young⁸, Jeffrey De Fauw^{2,3} & Shrivya Shetty^{1,2,4}

Screening mammography aims to identify breast cancer at earlier stages of the disease, when treatment can be more successful¹. Despite the existence of screening programmes worldwide, the interpretation of mammograms is affected by high rates of false positives and false negatives². Here we present an artificial intelligence (AI) system that is capable of surpassing human experts in breast cancer prediction. To assess its performance in the clinical setting, we curated a large representative dataset from the UK and a large enriched dataset from the USA. We show an absolute reduction of 5.7% and 1.2% (USA and UK) in false positives and 9.4% and 2.7% in false



ASSISTENTE DE VOZ

- Google Assistant
- Siri (Apple)
- Alexa (Amazon)
- Bixby (Samsung)
- Cortana (Microsoft)



TRADUÇÃO DE LÍNGUAS

- Google Translator
- Smart Voice Translator
- Letrans



FINANÇAS

- Busca por informações que podem afetar preço de ativos negativamente ou positivamente
- Predição de preço de ativos da bolsa



MAIS ALGUMAS APLICAÇÕES

- 30 aplicações:
 - <http://www.yaronhadad.com/deep-learning-most-amazing-applications/>

